

AML/KYC Onboarding Analytics

**Risk Assessment and
Process Optimization in
Fintech Operations**

AML/KYC Onboarding Analytics

1. Resumen Ejecutivo

El proceso de onboarding representa una de las etapas más críticas para las entidades financieras y fintechs, ya que deben equilibrar dos objetivos fundamentales: proporcionar una experiencia rápida y eficiente para el cliente y, al mismo tiempo, cumplir con los requisitos regulatorios relacionados con KYC (Know Your Customer) y AML (Anti-Money Laundering).

El objetivo principal de este proyecto fue analizar un proceso de onboarding fintech mediante técnicas de análisis de datos, visualización interactiva y Machine Learning para identificar los factores que influyen en la duración del proceso y en los resultados finales de aprobación o rechazo.

Para ello se desarrolló un dataset sintético inspirado en procesos reales de onboarding KYC/AML, compuesto por 300 casos y 1.194 eventos de onboarding entre enero y junio de 2026. Los datos fueron almacenados en PostgreSQL utilizando un modelo estrella (Star Schema) y posteriormente analizados mediante Power BI y Python.

El análisis permitió identificar que la calidad documental y el nivel de riesgo son los principales factores que afectan al proceso. Además, se evaluó el impacto de un workflow integrado diseñado para consolidar varias herramientas de cumplimiento en una única plataforma operativa.

Finalmente, se implementó un modelo de Árbol de Decisión que alcanzó una precisión del 85% al predecir resultados de onboarding. El modelo reveló que el estado de la documentación es el factor más influyente en las decisiones de aprobación o rechazo, seguido por el Risk Score.

Los resultados obtenidos sugieren que las iniciativas de integración tecnológica pueden mejorar significativamente la eficiencia operativa, mientras que la calidad documental y la evaluación de riesgo continúan siendo los principales elementos que determinan el resultado final del proceso de onboarding.

2. Introducción

2.1 Contexto del Negocio

Las entidades financieras modernas operan en un entorno altamente regulado donde la incorporación de nuevos clientes requiere controles exhaustivos relacionados con la prevención del fraude, el blanqueo de capitales y la financiación del terrorismo.

Los procesos KYC (Know Your Customer) y AML (Anti-Money Laundering) constituyen mecanismos fundamentales para garantizar el cumplimiento normativo y reducir los riesgos asociados a la actividad financiera.

Sin embargo, la creciente digitalización de los servicios financieros ha generado una presión constante para acelerar los procesos de onboarding y mejorar la experiencia del cliente. Como consecuencia, muchas organizaciones están invirtiendo en nuevas herramientas tecnológicas destinadas a optimizar los flujos de trabajo y reducir los tiempos operativos.

2.2 Problema de Negocio

Una de las principales dificultades en los procesos de onboarding consiste en equilibrar eficiencia operativa y cumplimiento regulatorio.

Procesos excesivamente lentos pueden afectar negativamente la experiencia del cliente y aumentar los costes operativos. Por otro lado, una reducción inadecuada de controles puede incrementar el riesgo de incumplimiento normativo y exposición a actividades ilícitas.

En este contexto surge la necesidad de comprender qué factores tienen un mayor impacto sobre la duración del onboarding y cuáles influyen directamente en las decisiones finales de aprobación o rechazo.

2.3 Objetivos del Proyecto

El objetivo general del proyecto es analizar el rendimiento de un proceso de onboarding fintech mediante técnicas de Data Analytics y Machine Learning.

Los objetivos específicos son:

- Analizar los factores que influyen en la duración del onboarding.
- Evaluar el impacto de la calidad documental sobre el proceso.
- Estudiar la relación entre el nivel de riesgo y los tiempos de revisión.
- Analizar el efecto de diferentes workflows operativos sobre la eficiencia del proceso.
- Implementar un modelo de Machine Learning capaz de identificar las variables más relevantes en las decisiones finales de onboarding.

2.4 Preguntas de Investigación

El proyecto busca responder a las siguientes preguntas:

1. ¿Qué factores aumentan el tiempo de onboarding?
2. ¿La calidad documental genera retrasos en el proceso?
3. ¿Los clientes de mayor riesgo requieren revisiones adicionales?
4. ¿La integración de herramientas de cumplimiento mejora la eficiencia operativa?
5. ¿Qué variables tienen mayor impacto en las decisiones finales de aprobación o rechazo?

3. Descripción del Dataset

3.1 Diseño del Dataset

Para el desarrollo del proyecto se creó un dataset sintético inspirado en procesos reales de onboarding KYC/AML utilizados por entidades financieras y fintechs.

El objetivo no fue replicar una organización específica, sino simular un entorno operativo realista que permitiera analizar diferentes escenarios relacionados con riesgo, documentación, tiempos de procesamiento y resultados finales.

El dataset está compuesto por:

- 300 casos de onboarding.
- 1.194 eventos de onboarding.
- Período de análisis: enero – junio de 2026.
- Base de datos PostgreSQL.
- Modelo Estrella (Star Schema).

La estructura del dataset permite analizar tanto el comportamiento individual de cada solicitud como el rendimiento general del proceso.

3.2 Variables Principales

Las principales variables utilizadas durante el análisis fueron:

- **Risk Score**

Representa una puntuación numérica utilizada para estimar el nivel de riesgo asociado a cada cliente.

- **Risk Level**

Clasificación derivada del Risk Score:

- Low Risk (0–24)
- Medium Risk (25–49)
- High Risk (50–75)

- **Documentation Status**

Indica la calidad y estado de la documentación proporcionada durante el onboarding.

Categorías principales:

- OK
- Incomplete
- Expired
- Suspicious

- **Workflow Type**

Representa el flujo operativo utilizado durante la revisión del onboarding.

Categorías:

- Manual Workflow (Manual)
- Integrated Workflow (Automatic)

Estado Final

Resultado final del proceso:

- Approved
 - Rejected
-

3.3 Metodología de Scoring de Riesgo

Con el objetivo de simular procesos modernos de evaluación de riesgo, se incorporó una variable denominada Risk Score.

La puntuación fue generada mediante reglas de negocio inspiradas en metodologías reales utilizadas en procesos de onboarding y evaluación de clientes.

El Risk Score fue creado de forma independiente al dataset analítico y posteriormente incorporado como una variable adicional para enriquecer el análisis.

La clasificación utilizada fue la siguiente:

Categoría	Rango
Low Risk	0 – 24
Medium Risk	25 – 49
High Risk	50 – 75

Esta variable permitió analizar la relación entre riesgo, tiempos de onboarding y resultados finales.

Posteriormente también fue utilizada como variable de entrada para el modelo de Machine Learning.

3.4 Workflow Type: Manual vs Integrated Workflow

Con el fin de simular iniciativas de mejora operativa habituales en fintechs modernas, el dataset incorpora una variable denominada Workflow Type.

Esta variable representa dos enfoques distintos para la ejecución de revisiones de onboarding:

Manual Workflow (Manual)

Los analistas trabajan utilizando múltiples herramientas independientes para realizar controles KYC, KYB, screening, revisión documental y evaluación de riesgo.

Integrated Workflow (Automatic)

Los analistas utilizan una plataforma integrada que consolida los resultados de diferentes controles de cumplimiento en una única interfaz operativa.

Es importante destacar que la categoría "Automatic" no representa decisiones automáticas ni sustitución de analistas mediante inteligencia artificial.

El objetivo de este workflow consiste exclusivamente en mejorar la eficiencia operativa mediante la integración tecnológica de herramientas previamente separadas.

Las decisiones finales continúan siendo tomadas por analistas humanos en ambos tipos de workflow.

La inclusión de esta variable permite evaluar si la integración tecnológica puede reducir los tiempos de onboarding sin modificar los criterios de decisión relacionados con riesgo y cumplimiento normativo.

4. Preparación y Validación de Datos

Antes de iniciar el análisis se realizaron diferentes actividades de preparación y validación de datos para garantizar la consistencia del dataset.

Las principales tareas incluyeron:

- Validación de tipos de datos.
- Revisión de consistencia temporal.
- Verificación de relaciones entre tablas.
- Integración del sistema de Risk Scoring.
- Generación de la dimensión calendario (dim_fecha).
- Revisión de valores relacionados con tiempos de onboarding.
- Validación de métricas utilizadas posteriormente en Power BI.

Estas actividades permitieron asegurar la calidad de los datos utilizados durante el análisis exploratorio, la visualización interactiva y el desarrollo del modelo de Machine Learning.

5. Diseño de la Base de Datos


5.1 Modelo Estrella (Star Schema)

Para organizar los datos de forma eficiente se implementó un modelo dimensional basado en la arquitectura Star Schema.

Este enfoque es ampliamente utilizado en proyectos de Business Intelligence debido a su simplicidad, rendimiento y facilidad para realizar análisis multidimensionales.

El modelo está compuesto por una tabla de hechos central y varias tablas dimensionales que proporcionan contexto adicional para el análisis.

Figura 1. Modelo Estrella del Proyecto



La tabla de hechos almacena los eventos de onboarding, mientras que las tablas dimensionales contienen información relacionada con clientes, fechas, niveles de riesgo, canales y etapas del proceso.

Esta estructura permitió realizar análisis operativos y de negocio de forma eficiente mediante consultas SQL y visualizaciones en Power BI.

5.2 Tabla de Hechos

La tabla principal del modelo es **fact_onboarding_eventos**.

Esta tabla almacena los eventos generados durante el proceso de onboarding y contiene métricas operativas como:

- Tiempo de procesamiento.
- Estado del onboarding.
- Tipo de workflow.
- Nivel de riesgo.
- Resultado final.

La tabla de hechos constituye el núcleo del análisis realizado durante el proyecto.

5.3 Tablas Dimensionales

El modelo incorpora varias dimensiones que permiten segmentar y analizar los datos desde diferentes perspectivas.

- **dim_cliente**

Contiene información relacionada con los clientes incluidos en el proceso de onboarding.

- **dim_fecha**

Permite realizar análisis temporales utilizando meses, trimestres y períodos específicos.

- **dim_riesgo**

Contiene la clasificación de riesgo utilizada durante el análisis.

- **dim_etapa**

Representa las diferentes fases del proceso de onboarding.

- **dim_canal**

Permite analizar el origen de las solicitudes y comparar distintos canales operativos.

5.4 Beneficios del Modelo

La implementación del modelo estrella proporcionó varias ventajas para el proyecto:

- Mejor organización de los datos.
- Mayor eficiencia en consultas analíticas.
- Integración sencilla con Power BI.
- Escalabilidad para futuras ampliaciones del dataset.
- Separación clara entre métricas y dimensiones de análisis.

Gracias a esta estructura fue posible desarrollar un dashboard interactivo y realizar análisis exploratorios de forma eficiente.

6. Análisis Exploratorio de Datos (EDA)

El análisis exploratorio de datos tuvo como objetivo comprender la distribución de las principales variables del proceso de onboarding e identificar posibles patrones relacionados con tiempos de procesamiento, niveles de riesgo y resultados finales.

Se prestó especial atención a las siguientes variables:

- Risk Level
- Risk Score
- Documentation Status
- Workflow Type
- Estado Final

El análisis permitió evaluar la relación entre el riesgo y la duración del onboarding, así como el impacto de la documentación sobre los resultados operativos.

Además, se estudió el comportamiento de los diferentes workflows operativos para identificar posibles oportunidades de mejora en la eficiencia del proceso.

Los hallazgos obtenidos durante esta fase sirvieron como base para el desarrollo del dashboard interactivo en Power BI y para la posterior construcción del modelo de Machine Learning.


7. Dashboard Interactivo en Power BI

El dashboard interactivo fue desarrollado en Power BI con el objetivo de visualizar los principales indicadores operativos del proceso de onboarding.

La solución permite analizar la relación entre riesgo, documentación, tiempos de procesamiento y resultados operativos mediante filtros dinámicos e indicadores clave de rendimiento (KPIs).

El dashboard fue diseñado para facilitar la toma de decisiones y proporcionar una visión global del rendimiento del proceso de onboarding.

Figura 2. Dashboard Principal de Onboarding



7.1 KPIs Principales

El dashboard incorpora tres indicadores principales:

1. Total Cases

Representa el número total de casos incluidos en el análisis para el período seleccionado.

2. Avg Hours

Muestra el tiempo promedio de procesamiento de los casos de onboarding.

3. Total Events

Indica el volumen total de eventos registrados dentro del proceso.

Estos indicadores proporcionan una visión general del rendimiento operativo antes de realizar análisis más detallados.

7.2 Distribución del Riesgo

El gráfico de distribución de riesgo permite visualizar la proporción de clientes clasificados como:

- Low Risk
- Medium Risk
- High Risk

La mayor parte de los casos se concentra en las categorías Low y Medium Risk, mientras que los clientes High Risk representan una proporción menor del volumen total.

Esta distribución es consistente con los procesos habituales de onboarding en entidades financieras.

7.3 Impacto de la Documentación

Dos visualizaciones permiten analizar la influencia de la documentación sobre el proceso.

Avg Hours por Estado de Documentación

Este gráfico muestra el tiempo promedio requerido para procesar casos según la calidad documental presentada.

Los casos con documentación incompleta o expirada presentan tiempos de procesamiento superiores debido a revisiones adicionales y solicitudes de información complementaria.

Total Events por Estado de Documentación

Este gráfico muestra la distribución de los diferentes estados documentales registrados durante el proceso.

La mayoría de los casos presentan documentación completa, mientras que los estados Incomplete, Expired y Suspicious representan una proporción significativamente menor.

7.4 Workflow Analysis

El dashboard incorpora una comparación entre dos modelos operativos:

- Manual Workflow (Manual)
- Integrated Workflow (Automatic)

El objetivo de esta comparación es evaluar el impacto de la integración tecnológica sobre la eficiencia del proceso.

El Integrated Workflow representa una iniciativa destinada a consolidar múltiples herramientas de cumplimiento dentro de una única plataforma operativa.

Los resultados sugieren que la integración de herramientas puede reducir los tiempos de procesamiento y aumentar la productividad de los analistas, manteniendo los mismos criterios de cumplimiento normativo.

7.5 Filtros Interactivos

El dashboard incluye varios filtros dinámicos que permiten realizar análisis específicos:

Month

Permite analizar la evolución de los indicadores entre enero y junio de 2026.

Risk Level

Facilita la segmentación de clientes según su nivel de riesgo.

Workflow Type

Permite comparar el rendimiento de los diferentes workflows operativos.

Estos filtros proporcionan flexibilidad al usuario y facilitan el análisis multidimensional de los datos.

8. Resultados de Negocio

El análisis realizado permitió identificar varios factores que influyen directamente en el rendimiento del proceso de onboarding.

8.1 Impacto de la Documentación

La calidad de la documentación presentada por los clientes demostró ser uno de los factores más relevantes del proceso.

Los casos con documentación incompleta, expirada o sospechosa requirieron revisiones adicionales y generaron mayores tiempos de procesamiento.

Por el contrario, los clientes que proporcionaron documentación completa fueron procesados de forma más eficiente.

8.2 Riesgo y Complejidad Operativa

El nivel de riesgo también mostró una influencia significativa sobre el onboarding.

Los clientes clasificados como High Risk suelen requerir verificaciones adicionales y controles más exhaustivos, aumentando el esfuerzo operativo necesario para completar el proceso.

Este comportamiento es consistente con las prácticas habituales de cumplimiento normativo en el sector financiero.

8.3 Integrated Workflow

Uno de los objetivos del proyecto consistió en evaluar el impacto de una iniciativa de integración tecnológica dentro del proceso de onboarding.

El Integrated Workflow representa un entorno donde diferentes herramientas de cumplimiento fueron consolidadas en una única plataforma operativa.

Los resultados sugieren que esta integración puede reducir los tiempos de procesamiento y mejorar la productividad de los analistas al disminuir las tareas manuales y la necesidad de utilizar múltiples sistemas.


Es importante destacar que la integración tecnológica no modifica los criterios regulatorios ni las decisiones finales de cumplimiento.

8.4 Principales Hallazgos

Los principales hallazgos del proyecto fueron:

- La documentación tiene un impacto significativo sobre la eficiencia operativa.
- Los clientes de mayor riesgo requieren revisiones adicionales.
- La integración de herramientas puede mejorar la productividad de los analistas.
- La calidad de los datos continúa siendo el factor más importante para la toma de decisiones.

Árbol de Decisión para la Predicción de Resultados de Onboarding



9. Machine Learning – Árbol de Decisión

Con el objetivo de complementar el análisis descriptivo realizado en Power BI, se desarrolló un modelo de Machine Learning utilizando un Árbol de Decisión (Decision Tree Classifier).

El objetivo del modelo consistió en identificar qué variables tienen mayor influencia sobre los resultados finales del proceso de onboarding.

Las variables utilizadas fueron:

- Risk Score
- Documentation Status
- Workflow Type

La variable objetivo fue:

- **Estado Final (Approved / Rejected)**

9.1 Preparación del Modelo

Las variables categóricas fueron transformadas mediante técnicas de codificación para permitir su utilización dentro del algoritmo.

Posteriormente, el dataset fue dividido en:

- 80% entrenamiento
- 20% validación

Esta división permitió evaluar el rendimiento del modelo utilizando datos no vistos previamente.

9.2 Resultados

El modelo alcanzó una precisión aproximada del 85%.

Este resultado indica que el algoritmo fue capaz de identificar correctamente la mayoría de los resultados de onboarding presentes en el dataset.

9.3 Interpretación del Árbol

El Árbol de Decisión identificó **el estado de la documentación** como la variable más influyente para predecir los resultados finales del onboarding. Esta variable aparece en el nodo raíz del modelo, indicando que fue el criterio principal utilizado para separar los casos aprobados y rechazados.

La segunda variable más relevante fue el **Risk Score**, que aparece repetidamente en diferentes niveles del árbol y contribuye significativamente a la clasificación de los clientes según su nivel de riesgo.

Por el contrario, el Workflow Type (Manual Workflow vs Integrated Workflow) no tuvo una influencia significativa sobre las decisiones finales del modelo.

Este resultado fue especialmente interesante, ya que inicialmente se esperaba que el Risk Score fuera el factor dominante. Sin embargo, el análisis reveló que la calidad de la documentación tuvo una influencia aún mayor sobre los resultados del onboarding.

Los hallazgos sugieren que la integración tecnológica puede mejorar la eficiencia operativa y reducir tiempos de procesamiento, pero las decisiones regulatorias continúan dependiendo principalmente de la calidad documental y de la evaluación del riesgo.

10. Conclusiones y Recomendaciones

10.1 Conclusiones

El objetivo principal de este proyecto fue analizar un proceso de onboarding KYC/AML mediante técnicas de Data Analytics y Machine Learning para identificar los factores que influyen en la eficiencia operativa y en los resultados finales de aprobación o rechazo.

Los resultados obtenidos permitieron responder a las preguntas de investigación planteadas al inicio del proyecto.

En primer lugar, se observó que la calidad de la documentación tiene un impacto significativo sobre el proceso de onboarding. Los casos con documentación incompleta, expirada o sospechosa requieren revisiones adicionales y generan mayores tiempos de procesamiento.

En segundo lugar, el nivel de riesgo también influye en la complejidad del proceso. Los clientes clasificados como High Risk suelen requerir controles adicionales y análisis más exhaustivos antes de alcanzar una decisión final.

Asimismo, el análisis realizado en Power BI mostró que la integración de herramientas de cumplimiento dentro de un único entorno operativo puede contribuir a reducir los tiempos de onboarding y mejorar la eficiencia del proceso.

Finalmente, el modelo de Machine Learning confirmó que la documentación y el Risk Score son los principales factores que explican los resultados finales del onboarding. Por el contrario, el Workflow Type tuvo una influencia limitada sobre las decisiones regulatorias.

En conjunto, los resultados sugieren que las mejoras tecnológicas pueden aumentar la productividad operativa, mientras que las decisiones finales continúan dependiendo principalmente de la calidad de la información proporcionada por los clientes y de la evaluación del riesgo.